

Drei Mietrealitäten. Eine klare Umzugsentscheidung.

MietCheck verbindet amtlichen Wohnungsbestand, aktuellen Angebotsmarkt und persönliche Belastung – offen, reproduzierbar und mit sichtbarer Unsicherheit.

Leitfrage: Wie lässt sich der Umzugsaufschlag mit offenen Massendaten und räumlich belastbarem Machine Learning transparent quantifizieren?

Das Problem

Bestandsmiete, heutige Angebotsmiete und persönliche Wohnkosten beschreiben unterschiedliche Realitäten. Werden sie vermischt, entsteht Scheingenauigkeit. MietCheck hält sie getrennt und zeigt ihre Differenz als Entscheidungshilfe – nicht als Rechtsauskunft.

Der USP

Bestand

ML-Anker · Zensus 2022

Angebot

GREIX · 2026-Q1

Persönlich

Vertrag + Budget

Kein geprüftes Vergleichsangebot verbindet alle fünf Bausteine in einer quellenoffenen Anwendung: Bestand, aktueller Markt, persönliche Belastung, Modellunsicherheit und vollständig nachvollziehbare ML-Methode.

Projekt in Zahlen

**2,06 Mio.
Modellzeilen**

**1,18 Mio.
100-m-Zellen**

**37 + DE
GREIX-Profile**

**35
automatisierte
Tests**

Positionierung

- Explorative Entscheidungshilfe für Mietende und Umzugsinteressierte.
- Kein amtlicher Mietspiegel, keine adressgenaue Bewertung und keine Rechtsberatung.
- Öffentliche Quellen, versionierte Berichte, ausgeführte Notebooks und reproduzierbarer Build.

Nele Knaak · Matrikelnummer: [EINTRAGEN]

Ersatzleistung Big Data & Data Analytics · Prüfer/in: [EINTRAGEN] · Abgabe: [TT.MM.JJJJ]

Groß genug für Big Data – sauber genug für Reproduzierbarkeit

Zwei Datenwelten, methodisch getrennt

Quelle	Rolle	Umfang / Stand	Warum getrennt?
Zensus 2022	Trainingsziel + Strukturmerkmale	7 Produkte · 100-m-Gitter · Stichtag 15.05.2022	Amtlicher Wohnungsbestand
GREIX	Aktueller Angebotsmarkt	2.166 Quartalswerte · 2012-Q1–2026-Q1	Inserate statt Bestandsmieten

Vom Download zur App

[Download](#) → [Hash-Prüfung](#) → [Datenverträge](#) → [Join auf 100-m-Zellen](#) → [EDA](#) → [Spatial CV](#) → [Tuning](#) → [finaler Holdout](#) → [Kalibrierung](#) → [App](#)

Qualitätssicherung

- Offizielle Download-URLs und SHA-256-Manifest sichern Herkunft und Unverändertheit.
- Datenverträge prüfen Spalten, Typen, Schlüssel, Kategorien, Missingness und Join-Verluste.
- Ridge, LinearSVR und MLP erhalten Imputer und StandardScaler ausschließlich im Trainingsfold; Baumverfahren bleiben unskaliert.
- GREIX aktualisiert nur den Marktvergleich; er wird nicht als zeitlich unpassendes Trainingsziel verwendet.

Modellmatrix

Dimension	Kategorien
Ziel	durchschnittliche Nettokaltmiete in €/m ²
Raum	100-m-Zelle mit Koordinaten und 25-km-Block
Gebäudealter	bis 1990 / nach 1990
Wohnungsgröße	bis 65 m ² / über 65 m ²
Struktur	Gebäude-, Wohnungs-, Haushalts- und Bevölkerungsmerkmale

Reproduzierbare Kernschritte

Skript	Ergebnis
scripts/download_data.py	offizielle Rohdaten + Manifest
scripts/build_dataset.py	2.058.569 Modellzeilen
scripts/build_greix.py	aktuelle Zeitreihen und Marktprofile
scripts/train_final_model.py	Modellartefakt + Metadaten

Räumlich testen – nicht auf Nachbarzellen schummeln

Leakage-freier Split

1.518.322

Entwicklung · 465 Blöcke

263.789

Kalibrierung · 99 Blöcke

276.458

Finaltest · 99 Blöcke

100-m-Zellen werden zu 25-km-Raumblöcken gruppiert. Ganze Blöcke liegen ausschließlich in Entwicklung, Kalibrierung oder finalem Test; zwischen den drei Mengen gibt es keinen gemeinsamen Block.

Sieben Modellfamilien unter identischer Spatial CV

Rang	Modell	mittlerer CV-MAE	Entscheidung
1	HistGradientBoosting	1,305 €/m ²	finales Modell
2	Random Forest	1,320 €/m ²	Challenger
3	Decision Tree	1,393 €/m ²	verworfen
4	MLP	1,397 €/m ²	verworfen
5	Ridge	1,632 €/m ²	verworfen
6	LinearSVR	1,635 €/m ²	verworfen
7	Kategorienmedian	1,719 €/m ²	Baseline

Finaler unangetasteter Test

1,413
MAE €/m²
0,956
Median AE €/m²
0,584
R²
−38,3 %

vs. Baseline

Unsicherheit ohne Schönrechnen

Split Conformal Prediction wird ausschließlich auf der separaten Kalibrierungsmenge angepasst. Das nominale 90%-Intervall erreicht im räumlichen Test empirisch 86,8 %. Die Unterdeckung wird in App, Model Card und Risikoanalyse sichtbar ausgewiesen.


Wichtigster Befund: Neubauten generalisieren schwächer. Deshalb nutzt MietCheck kategoriespezifische Intervallbreiten.

Finale HGB-Konfiguration

learning_rate 0,06 · 300 Iterationen · 127 Blätter · mindestens 100 Zeilen je Blatt · L2-Regularisierung 5. Ergänzend schlägt RBF-SVR LinearSVR auf einer transparenten 10k-Machbarkeitsstichprobe, wird wegen der Skalierungskosten aber nicht auf 600.000 Zeilen trainiert.

PRODUKT

Methodik wird erst wertvoll, wenn sie verständlich ankommt



Berlin-Szenario: 70 m² · Baujahr 1985



Nutzerführung

- Region, Wohnfläche, Baujahr, aktuelle Kaltmiete und optionales Haushaltsnetto eingeben.
- Drei Vergleichswerte getrennt lesen; keine Zahl wird als „richtige Miete“ etikettiert.
- Marktverlauf, IQR, Modellband, Datenstand und Methodik direkt am Ergebnis prüfen.

Einsatzgrenzen

Fehlt im Modell	Wie MietCheck damit umgeht
Ausstattung, Energiezustand, Etage, Mikrolage	keine adressgenaue Behauptung
lokale Angebote außerhalb der 37 GREIX-Märkte	keine erfundenen Marktwerte
stabile 90-%-Coverage unter räumlichem Shift	empirische 86,8 % anzeigen
rechtliche Besonderheiten	klare Abgrenzung von Mietspiegel und Rechtsberatung

QUA³CK als überprüfbare Beweiskette

Phase	Nachweis im Projekt
Q · Question	Leitfrage, Zielgruppe, USP und Erfolgsgates
U · Understanding	Datenherkunft, EDA, Datenqualität und StandardScaler
A ¹ · Auswahl	7 Kandidaten unter Spatial CV plus Linear- vs. RBF-SVR
A ² · Anpassung	4 Feature-Ablationen
A ³ · Anwendung	8 HGB-Tunings und finales Artefakt
C · Comparing	finaler Holdout, Unsicherheit und Subgruppen
K · Knowledge	Streamlit-App, USP und Grenzen

4/4 Rechennotebooks ausgeführt · 24/24 Codezellen · 0 Fehleroutputs · K-Phase als Transfer-Artefakt
· automatisierter Ausführungsbericht

Repository und Ausführung

Repository: github.com/neleknaak-31/MietCheck

Befehl	Zweck
<code>pip install -r requirements-dev.txt</code>	Laufzeit, Entwicklung und Tests installieren
<code>streamlit run app.py</code>	App lokal starten
<code>python -m pytest -q</code>	35 Tests ausführen
<code>python -m ruff check .</code>	Codequalität prüfen

Zentrale Quellen

- Statistische Ämter des Bundes und der Länder: Zensus 2022, 100-m-Gitterdaten, Datenlizenz Deutschland – Namensnennung 2.0.
- Kiel Institut für Weltwirtschaft / VALUE: GREIX-Mietpreisindex, nominale Quartalswerte 2012-Q1 bis 2026-Q1.
- Projektberichte: DATA_CARD.md, MODEL_CARD.md, RISK_AND_ETHICS.md sowie versionierte JSON-Evaluationsberichte.

Fazit

Nicht eine „faire“ Miete, sondern drei sauber getrennte Realitäten. Der Mehrwert ist eine nachvollziehbare Umzugsentscheidung – mit Datenstand, Streuung und Modellgrenzen.